Statistique : méthodes scientifiques qui réunit des infos sur des données diverses nombreuses, à analyser, commenter et critiquer ces données

population : ensemble sur lequel porte une étude statistique

individu : élément de population

caractère ou variable statistique = infos communes recueillie à propos de la population
=> noté par lettre majuscule : X, Y, ...

modalités ou valeurs : d'un caractère : différents états ou différentes valeurs que peut prendre le caractère
=> noté par x_m, ex : $x_1, x_2, \dots$ pour les modalités de la variable X
=> notés par y_m : ex : $y_1, y_2, \dots$ " Y
=> x_i pour une modalité quelconque

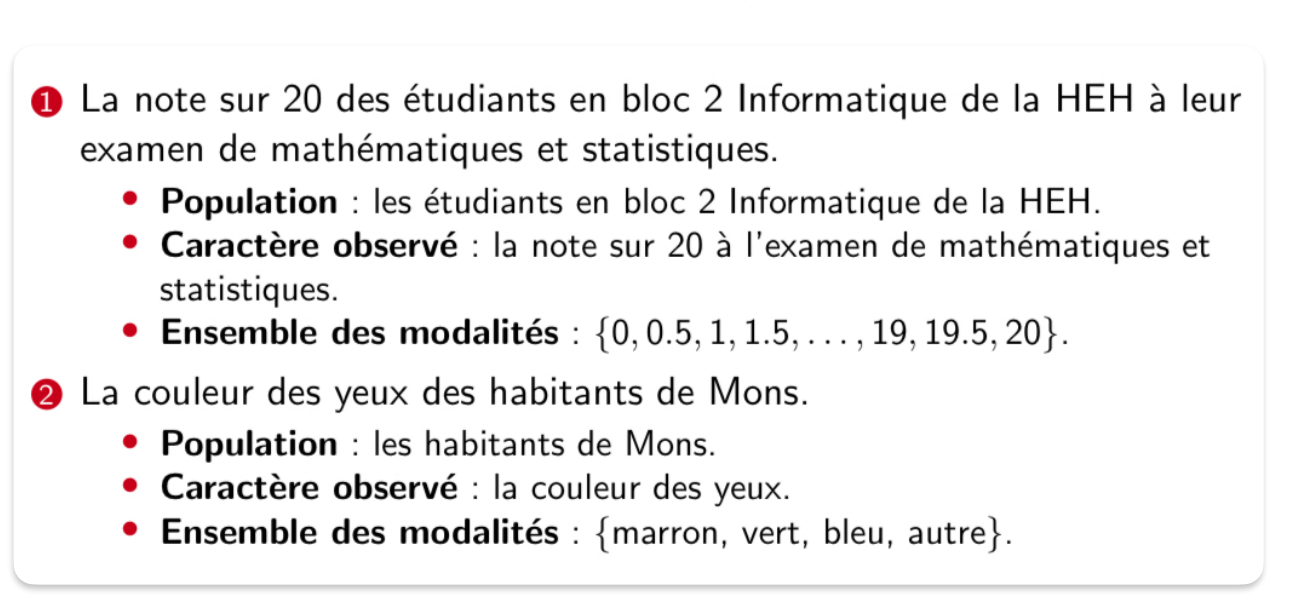

❶ La note sur 20 des étudiants en bloc 2 Informatique de la HEH à leur examen de mathématiques et statistiques.
- **Population** : les étudiants en bloc 2 Informatique de la HEH.
- **Caractère observé** : la note sur 20 à l'examen de mathématiques et statistiques.
- **Ensemble des modalités** : $\{0, 0.5, 1, 1.5, \dots, 19, 19.5, 20\}$.

❷ La couleur des yeux des habitants de Mons.
- **Population** : les habitants de Mons.
- **Caractère observé** : la couleur des yeux.
- **Ensemble des modalités** : {marron, vert, bleu, autre}.

si population trop grande : on prend une partie de la pop., app. échantillon

échantillon : = sous-ensemble de la population. On écrit n le nombre d'individus d'un échantillon. Il s'agit de la taille de l'échantillon

2 types de variables :

- variable quantitative : si ses modalités sont mesurables ou repérables par un nombre
  → discrète : si modalités isolées ou peu nombreuses ; souvent valeurs entières
  → continue : si modalités peuvent prendre n'importe quelles valeurs réelles dans un intervalle donné
- variable qualitative : si ses modalités expriment une qualité (couleur, nom, etc) et ne peuvent être mesurées par un nombre
  → nominale : si les modalités ne peuvent être classées
  → ordinale : si les modalités peuvent être classées, ordonnées selon un critère bien défini

Exemple :

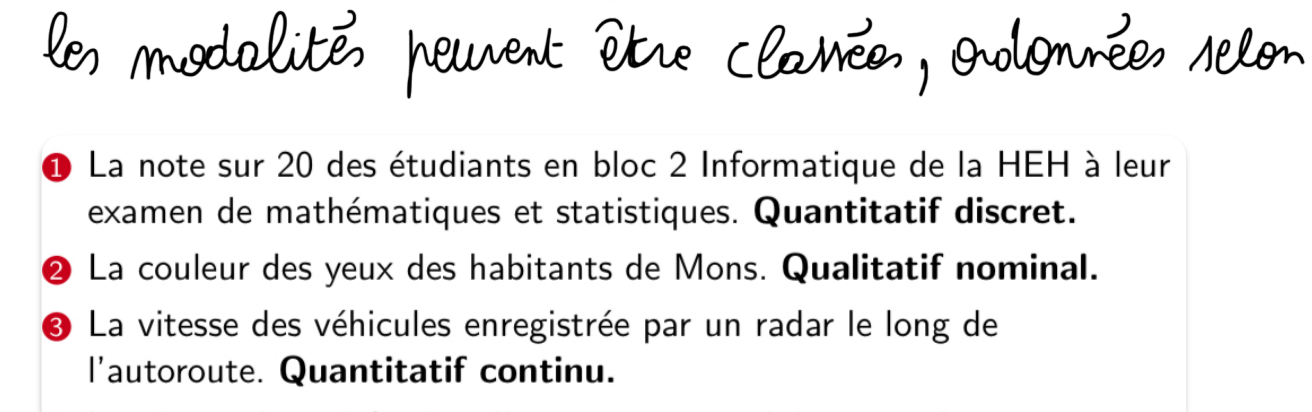

❶ La note sur 20 des étudiants en bloc 2 Informatique de la HEH à leur examen de mathématiques et statistiques. **Quantitatif discret.**
❷ La couleur des yeux des habitants de Mons. **Qualitatif nominal.**
❸ La vitesse des véhicules enregistrée par un radar le long de l'autoroute. **Quantitatif continu.**
❹ Le niveau de satisfaction d'un nouveau produit proposé par un supermarché (très statisfait, pas du tout satisfait, etc.). **Qualitatif ordinal.**

Objectif : objectif de la statistique descriptive : organiser et résumer les données afin d'en avoir une connaissance et une interprétation aisée
⟹ tableau de répartition, appelé tableau de distribution de fréquences et des graphiques ou diagrammes

---

Variable statistique qualitative

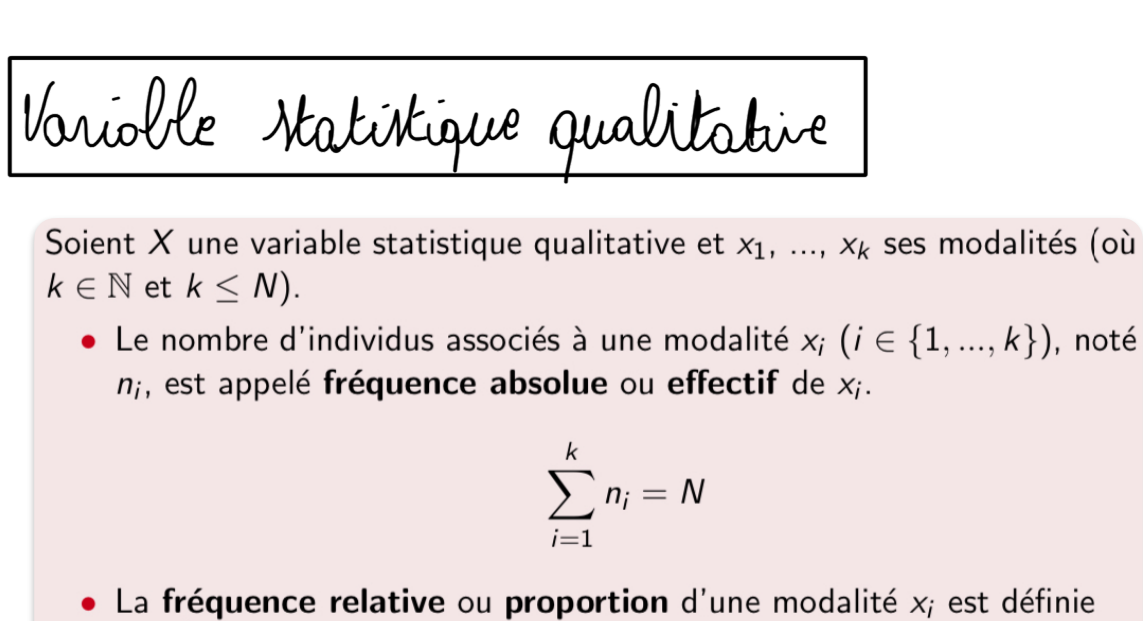

Soient X une variable statistique qualitative et $x_1, \dots, x_k$ ses modalités (où $k \in \mathbb{N}$ et $k \leq N$).
- Le nombre d'individus associés à une modalité x_i ($i \in \{1, \dots, k\}$), noté n_i, est appelé **fréquence absolue** ou **effectif** de x_i.

$$\sum_{i=1}^{k} n_i = N$$

- La **fréquence relative** ou **proportion** d'une modalité x_i est définie par $\frac{n_i}{N}$. On la note f_i.

$$\sum_{i=1}^{k} f_i = 1.$$

fréquence absolue ou effectif = $\sum_{i=1}^{k} m_i = N$
fréquence relative ou proportion = $\frac{m_i}{N} = f_i$ | $\sum_{i=1}^{k} f_i = 1$

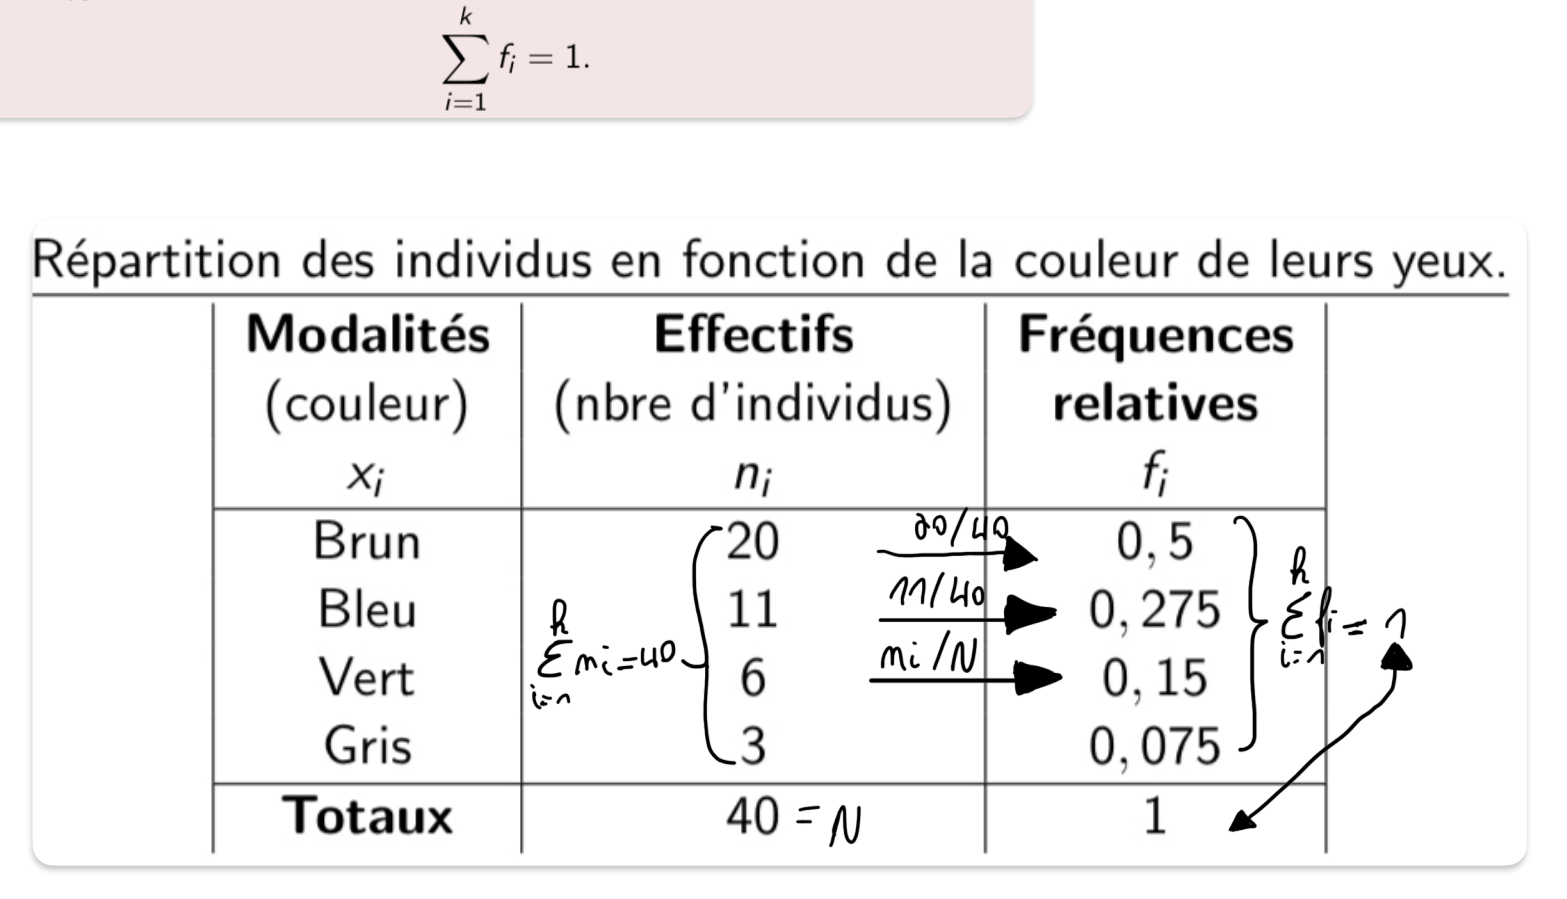

Répartition des individus en fonction de la couleur de leurs yeux.

Modalités (couleur) x_i	Effectifs (nbre d'individus) n_i	Fréquences relatives f_i
Brun	20	0,5
Bleu	11	0,275
Vert	6	0,15
Gris	3	0,075
Totaux	40 = N	1

$\sum_{i=1}^{k} m_i = 40$; 20/40 ; 11/40 ; m_i / N ; $\sum_{i=1}^{k} f_i = 1$

Données brutes récoltées =>

Données utilisées pour les diagrammes =>

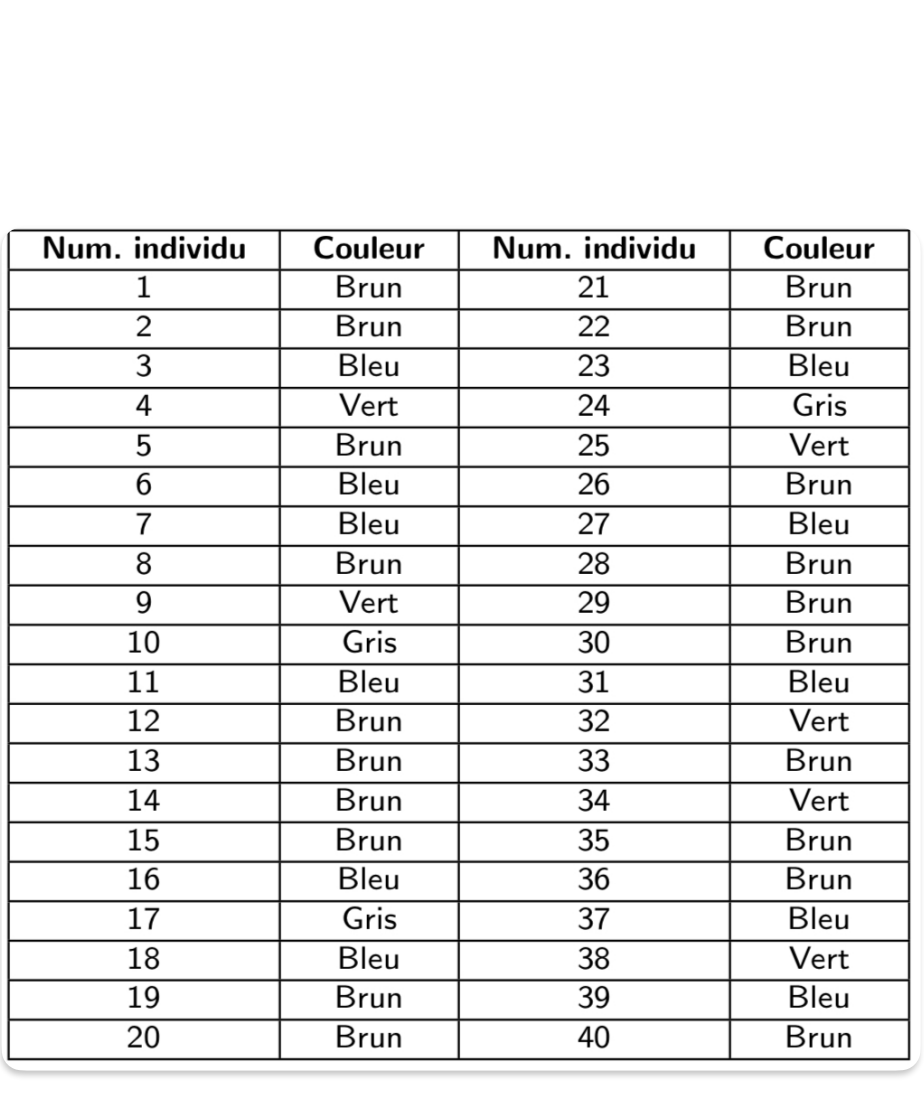

Num. individu	Couleur	Num. individu	Couleur
1	Brun	21	Brun
2	Brun	22	Brun
3	Bleu	23	Bleu
4	Vert	24	Gris
5	Brun	25	Vert
6	Bleu	26	Brun
7	Bleu	27	Bleu
8	Brun	28	Brun
9	Vert	29	Brun
10	Gris	30	Brun
11	Bleu	31	Bleu
12	Brun	32	Vert
13	Brun	33	Brun
14	Brun	34	Vert
15	Brun	35	Brun
16	Bleu	36	Brun
17	Gris	37	Bleu
18	Bleu	38	Vert
19	Brun	39	Bleu
20	Brun	40	Brun

Diagramme en colonnes : => 2 axes perpendiculaires

- Axe horizontal : segment de longueurs égales, séparé l'un de l'autre, les modalités de la variable statistique
- Axe vertical : On choisit une unité de mesure adoptée et on indique les effectifs (ou fréquences relatives)

=> couple $(x_i ; y_i)$ est représenté par un rectangle de hauteur n_i (ou f_i)

EX du cour

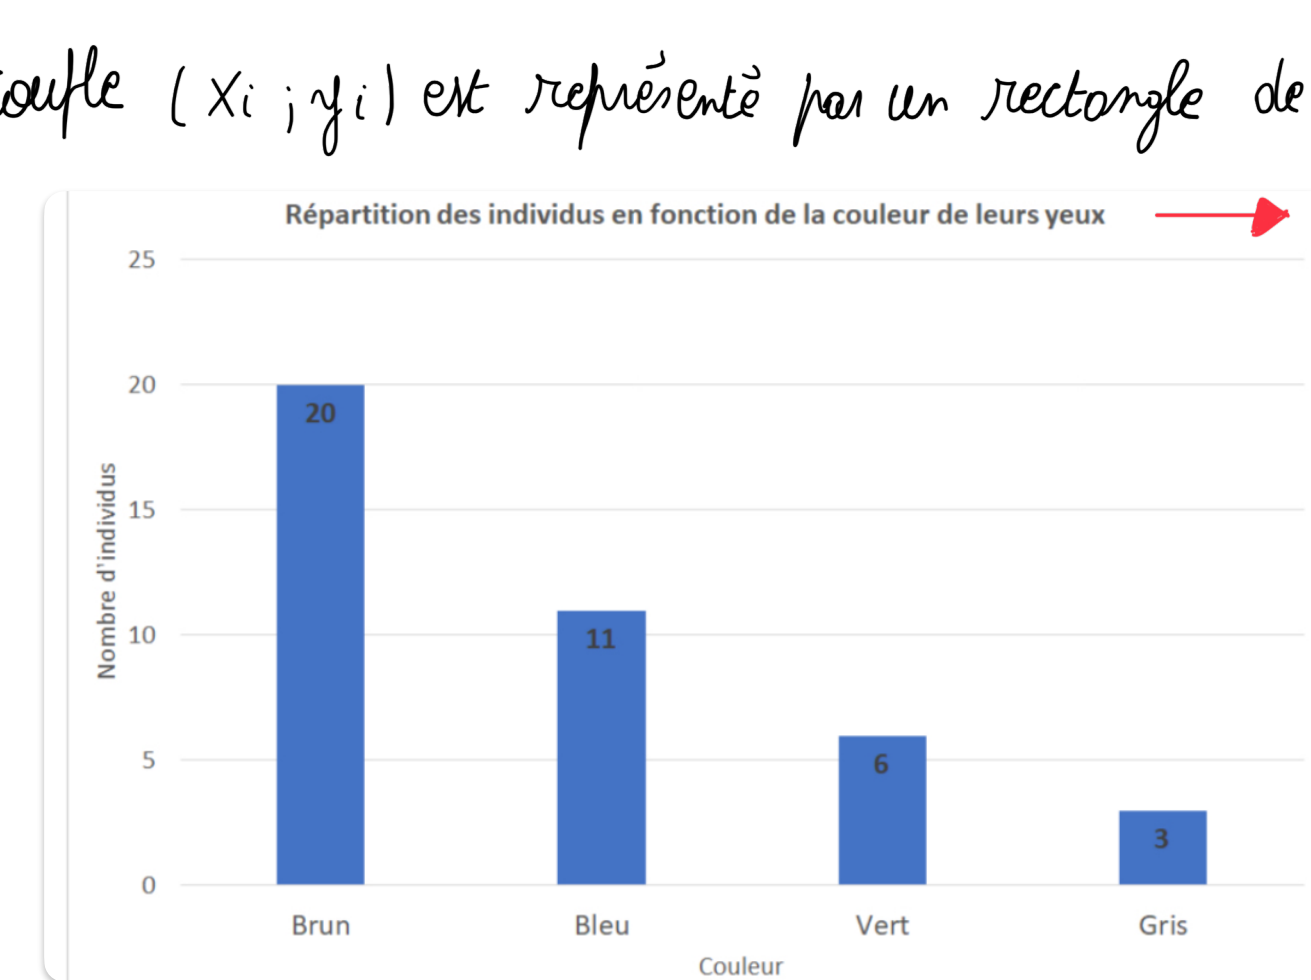

Tout graphique nécessite un titre ⚠
Sinon point en -

Diagramme circulaire : Cercle

- 1 secteur = 1 modalité et aire du secteur est proportionnelle au % de la modalité correspondante
- angle au centre = $f_i \cdot 360$

Ex du cours :

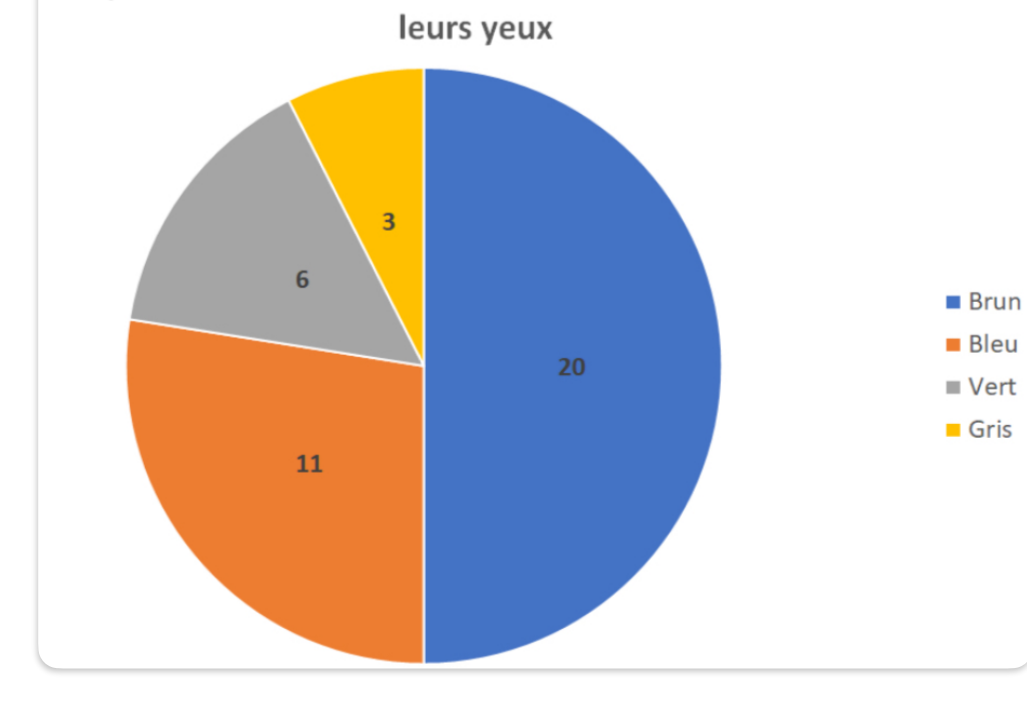

Résumé : variables qualitatives : qualité, pas nombres
↳ couleur, nom, ...
- nominales : si elles ne peuvent pas être classées
  ↳ ex : couleurs
- ordinales : si elles peuvent être classées, selon critère
  ↳ ex : bien, très bien, pas bien, ...

Formule : - fréquence absolue ou effectif de x_i : $\sum_{i=1}^{k} m_i = N$
- fréquence relative ou proportion de x_i : $\sum_{i=1}^{k} f_i = 1$ et $f_i = \frac{m_i}{N}$
notée f_i

2 représentations graphiques : colonnes et circulaire

Variables quantitatives :

1er cas : peu de modalités différentes

Si nombre k de modalité est petit comparé au N de la population, on présente les données comme pour les variables qualitatives

Données brutes :

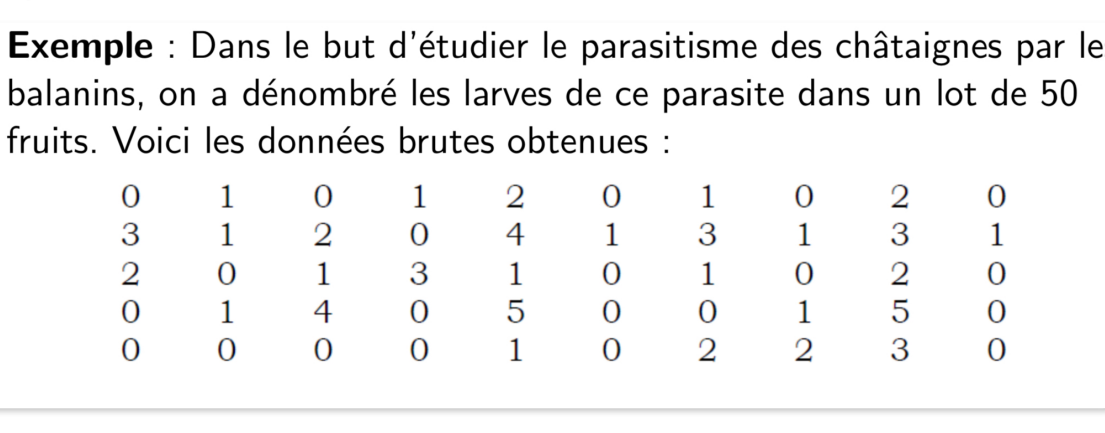

- **Exemple** : Dans le but d'étudier le parasitisme des châtaignes par les balanins, on a dénombré les larves de ce parasite dans un lot de 50 fruits. Voici les données brutes obtenues :

0	1	0	1	2	0	1	0	2	0
3	1	2	0	4	1	3	1	3	1
2	0	1	3	1	0	1	0	2	0
0	1	4	0	5	0	0	1	5	0
0	0	0	0	1	0	2	2	3	0

=> Variable quantitative discrète
petit nombre de modalités : 6 : {0, 1, 2, 3, 4, 5}

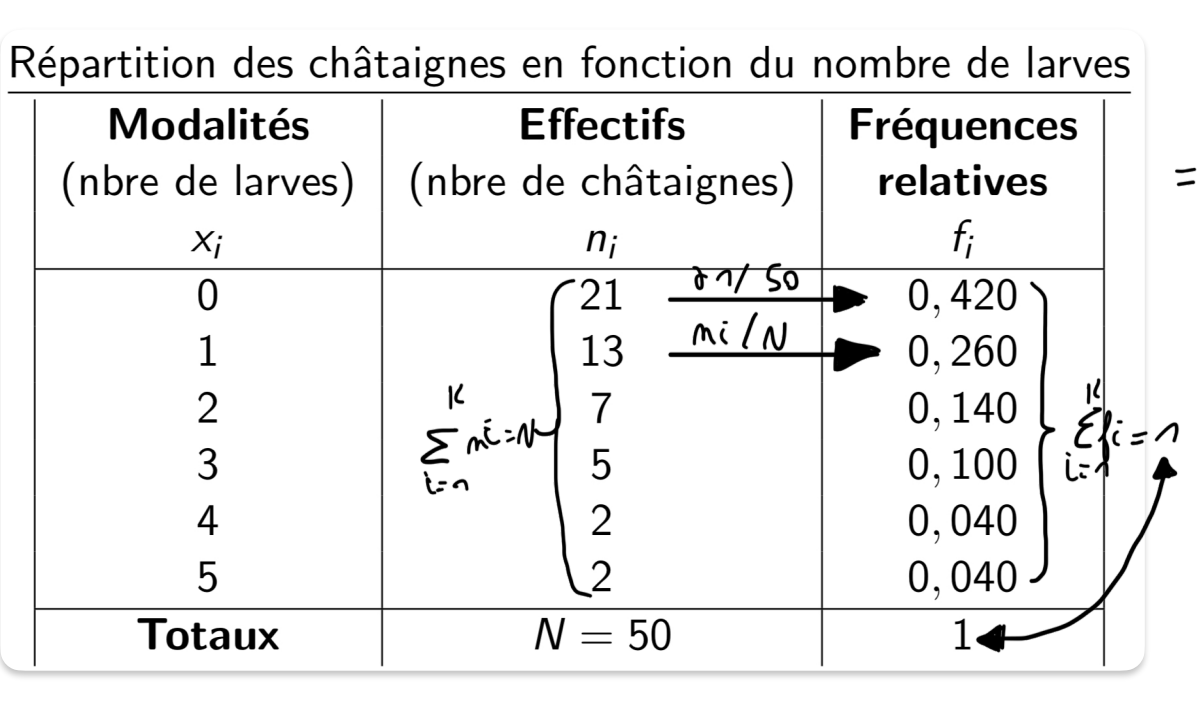

Répartition des châtaignes en fonction du nombre de larves

Modalités (nbre de larves) x_i	Effectifs (nbre de châtaignes) n_i	Fréquences relatives f_i
0	21	0,420
1	13	0,260
2	7	0,140
3	5	0,100
4	2	0,040
5	2	0,040
Totaux	$N = 50$	1

$\sum_{i=1}^{k} m_i = N$; 21/50 ; m_i / N ; $\sum_{i=1}^{k} f_i = 1$

= même formule que qualitatif

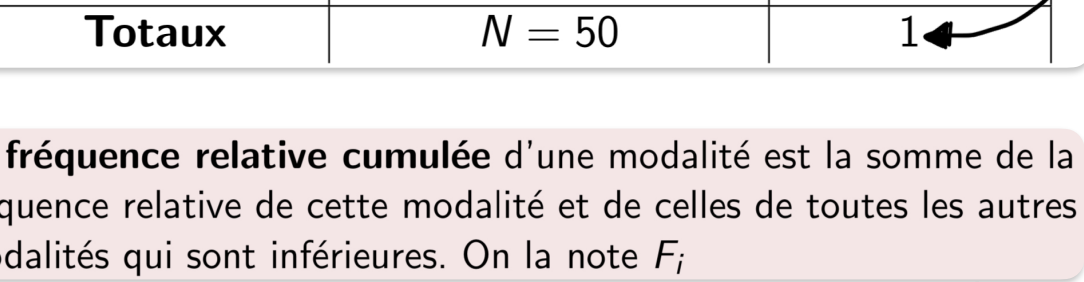

La **fréquence relative cumulée** d'une modalité est la somme de la fréquence relative de cette modalité et de celles de toutes les autres modalités qui sont inférieures. On la note F_i

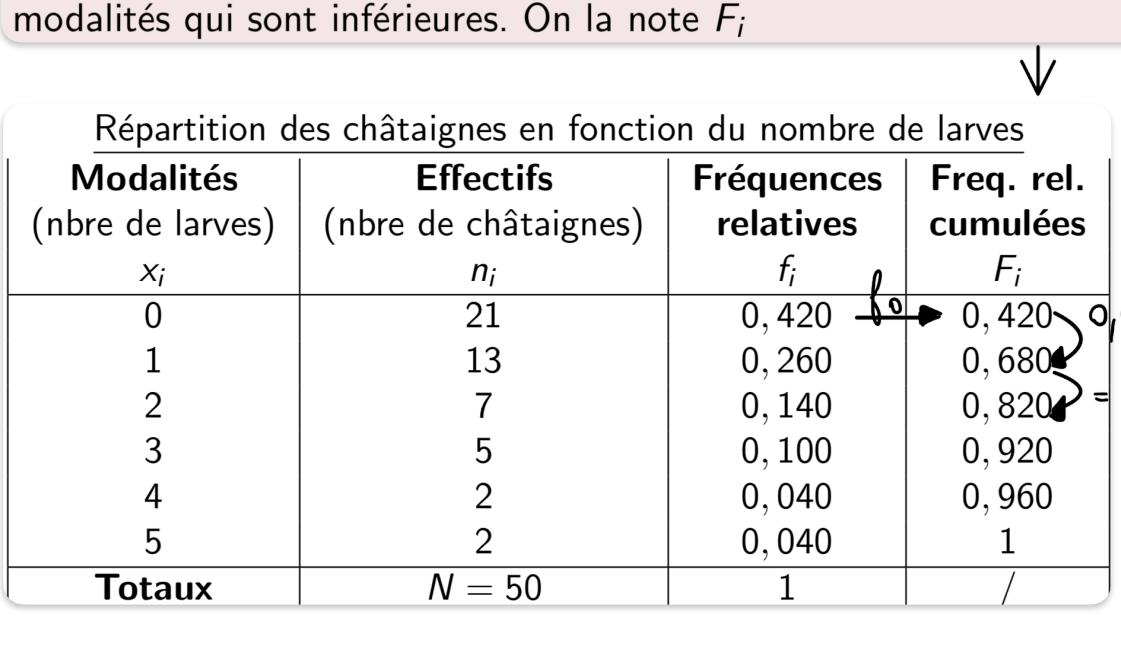

Répartition des châtaignes en fonction du nombre de larves

Modalités (nbre de larves) x_i	Effectifs (nbre de châtaignes) n_i	Fréquences relatives f_i	Freq. rel. cumulées F_i
0	21	0,420	0,420
1	13	0,260	0,680
2	7	0,140	0,820
3	5	0,100	0,920
4	2	0,040	0,960
5	2	0,040	1
Totaux	$N = 50$	1	/

f_0
$0{,}420 + f_1 = 0{,}420 + 0{,}260 = 0{,}680$
$= f_1 + f_2$

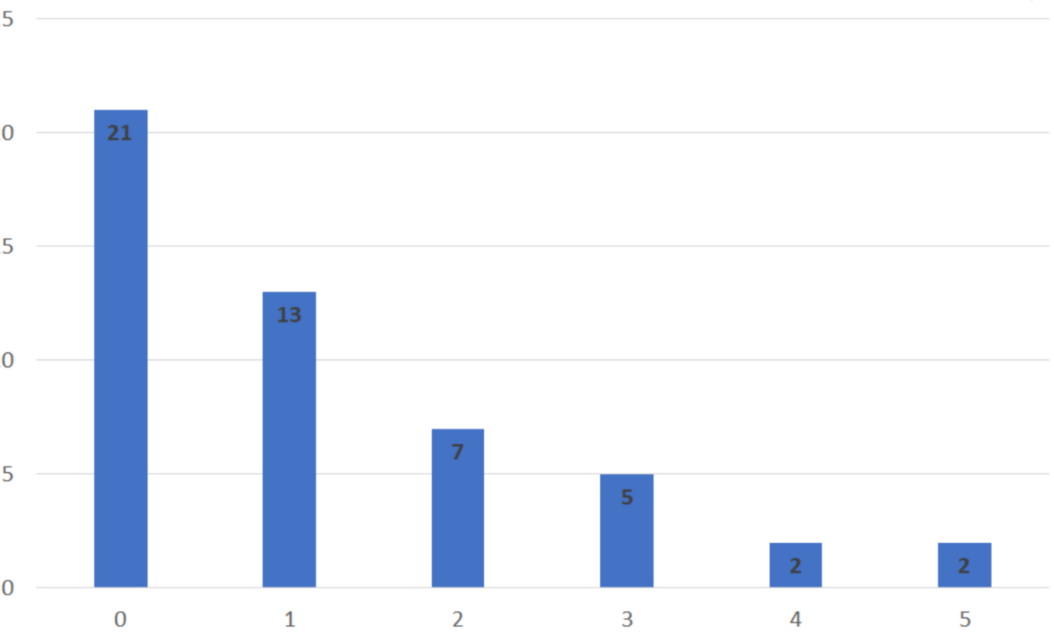

⚠ titre ⚠

→ données brutes traitées en diagramme en colonnes

2ème cas : - k de modalités est grand par rapport à la taille de la population
- cas les + fréquents : données toutes différentes ; variables statistiques quantitatives continues
- tableau de distribution de fréquences inutiles car trop de lignes et presque tous les effectifs vaudraient 1 => synthèse de données pas clair

→ Grouper les données en classe

Classe = - intervalle semi ouvert, noté $[b_{i-1} ; b_i[$ où - b_{i-1} = borne inférieure - b_i = borne supérieure
- Valeur x_i appartient à la classe $[b_{i-1} ; b_i[$ ∀ $b_{i-1} \leqslant x_i < b_i$

* milieu ou centre de la ième classe, noté m_i : $m_i = \frac{b_{i-1}+b_i}{2}$

* largeur ou amplitude de la ième classe, notée L_i : $L_i = b_i - b_{i-1}$

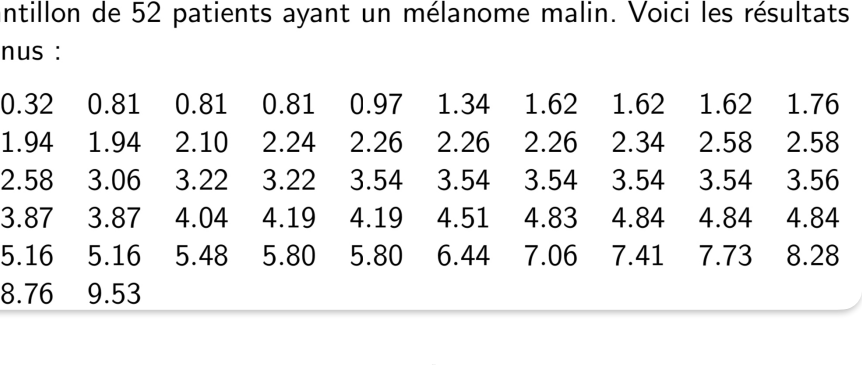

Un chercheur a mesuré l'épaisseur en mm d'une tumeur dans un échantillon de 52 patients ayant un mélanome malin. Voici les résultats obtenus :

0.32	0.81	0.81	0.81	0.97	1.34	1.62	1.62	1.62	1.76
1.94	1.94	2.10	2.24	2.26	2.26	2.26	2.34	2.58	2.58
2.58	3.06	3.22	3.22	3.54	3.54	3.54	3.54	3.54	3.56
3.87	3.87	4.04	4.19	4.19	4.51	4.83	4.84	4.84	4.84
5.16	5.16	5.48	5.80	5.80	6.44	7.06	7.41	7.73	8.28
8.76	9.53								

Données brutes
→ + petite donnée = 0,32 mm
→ + grande donnée = 9,53 mm

Recommandation (flemme de reformuler)

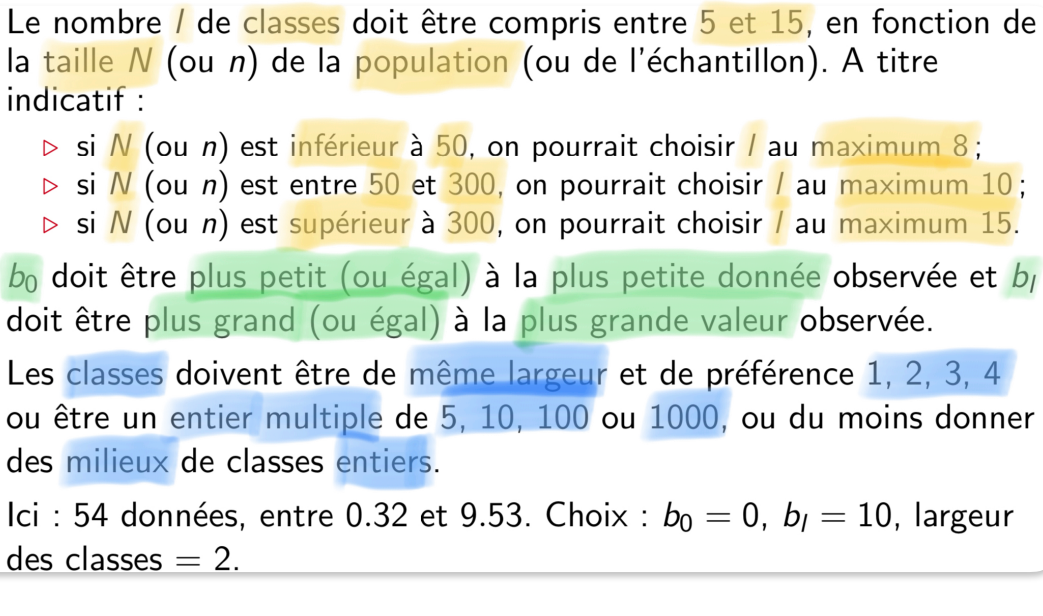

- Le nombre l de classes doit être compris entre 5 et 15, en fonction de la taille N (ou n) de la population (ou de l'échantillon). A titre indicatif :
  - ▷ si N (ou n) est inférieur à 50, on pourrait choisir l au maximum 8 ;
  - ▷ si N (ou n) est entre 50 et 300, on pourrait choisir l au maximum 10 ;
  - ▷ si N (ou n) est supérieur à 300, on pourrait choisir l au maximum 15.
- b_0 doit être plus petit (ou égal) à la plus petite donnée observée et b_l doit être plus grand (ou égal) à la plus grande valeur observée.
- Les classes doivent être de même largeur et de préférence 1, 2, 3, 4 ou être un entier multiple de 5, 10, 100 ou 1000, ou du moins donner des milieux de classes entiers.
- Ici : 54 données, entre 0.32 et 9.53. Choix : $b_0 = 0$, $b_l = 10$, largeur des classes = 2.

Tableau de distribution des fréquences : - remplace colonne modalité par colonne $[b_{i-1} ; b_i[$ des classes
- ajoute colonne m_i, m_i devient valeur représentant toutes les données d'une même classe
- notion d'effectif, fréquence relative cumulée s'étendent de façon évidente aux classes

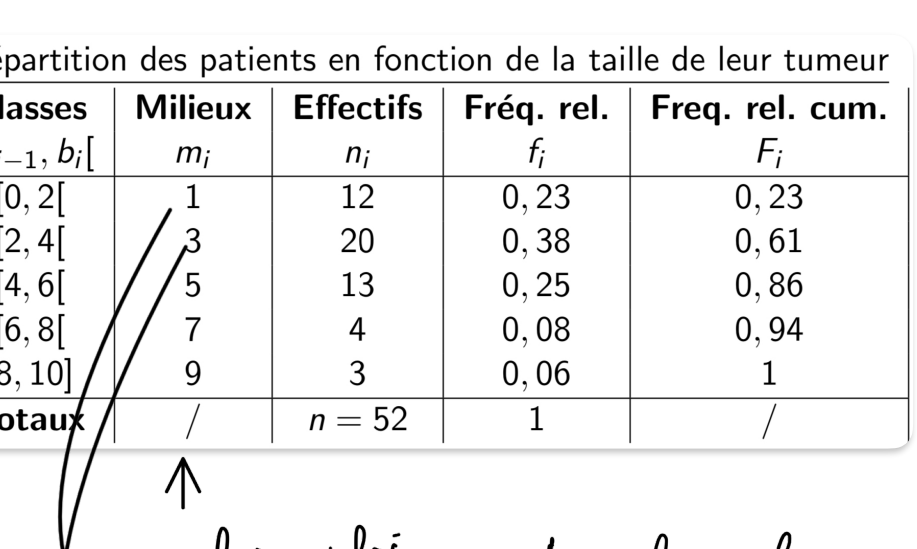

Répartition des patients en fonction de la taille de leur tumeur

Classes $[b_{i-1}, b_i[$	Milieux m_i	Effectifs n_i	Fréq. rel. f_i	Freq. rel. cum. F_i
[0, 2[	1	12	0,23	0,23
[2, 4[	3	20	0,38	0,61
[4, 6[	5	13	0,25	0,86
[6, 8[	7	4	0,08	0,94
[8, 10]	9	3	0,06	1
Totaux	/	$n = 52$	1	/

$m_i = \frac{b_{i-1}+b_i}{2}$
$= \frac{0+2}{2} = \frac{2}{2} = 1$
$= \frac{2+4}{2} = \frac{6}{3} = 2$
m_i = entier
=> respecte recommandations

$L_i = b_i - b_{i-1}$
$= 2 - 0 = 2$
$= 4 - 2 = 2$
} Bonne largeur comme définie au début de l'exo

Représentation graphique : — histogramme : - colonnes à rectangles juxtaposés
- modalités remplacées par des classes à intervalles successifs → pas utile de séparer rectangles

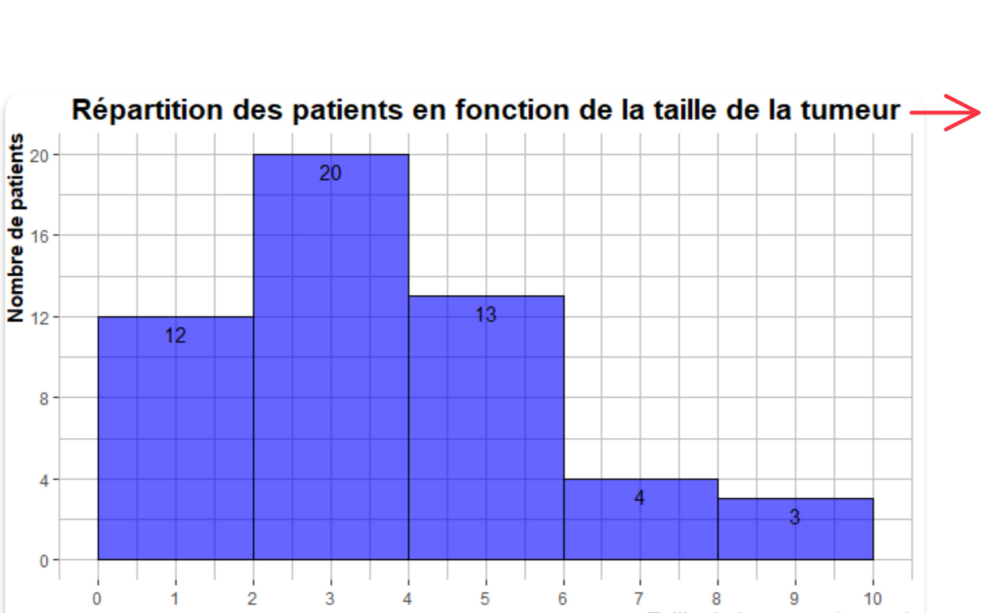

⚠ titre ⚠

- Polygone de fréquences : - ligne obtenue en joignant les milieux consécutifs des sommets des rectangles de l'histogramme
- On commence et termine sur l'axe horizontal en imaginant une classe de fréquence nulle avant la 1ère classe et une autre après la dernière classe et en considérant le point milieu de ces rectangles de hauteur nulle
- Préféré pour comparer différentes distributions

= sommet rectangle

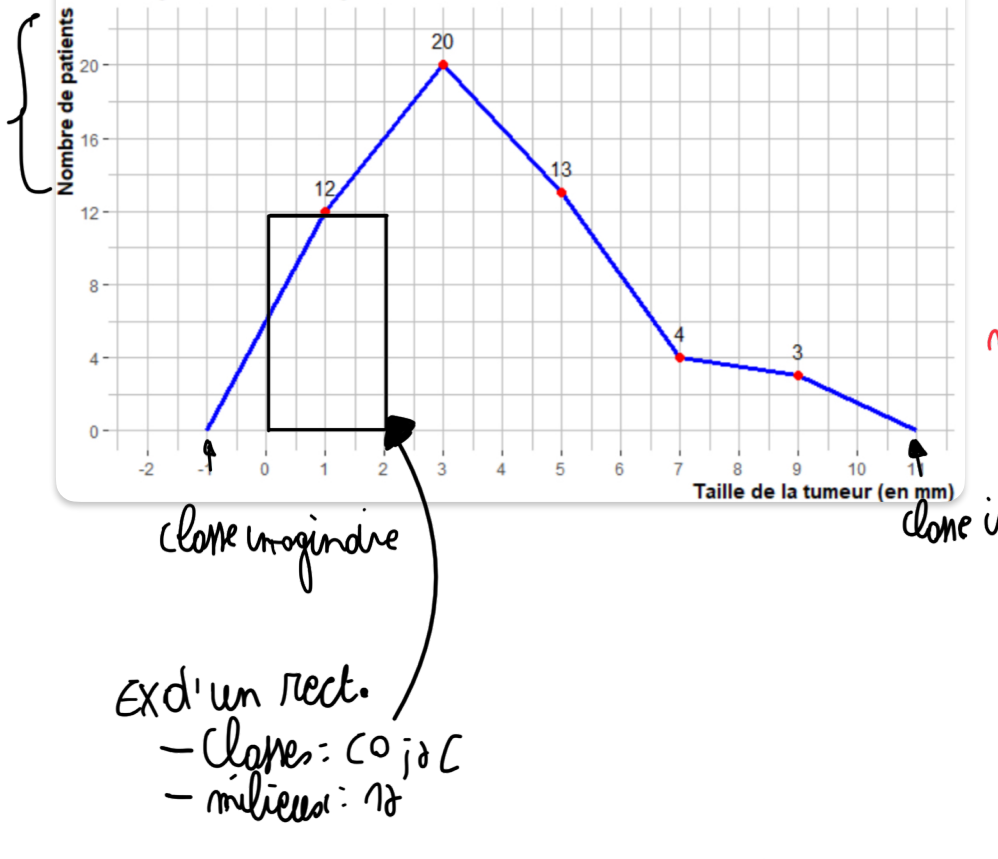

⚠ titre ⚠

Rappel : $m_i = \frac{b_{i-1}+b_i}{2}$

Ex d'un rect.
- Classes : [0 ; 2[
- milieux : 1

- Ogive des fréquences relatives cumulées :
  - axe horizontal : extrémités des classes du caractère étudié
  - axe vertical : effectifs cumulés ou les fréquences cumulées
  - On joint les points ayant pour :
    * abscisse la borne supérieure de la classe
    * ordonnée la fréquence cumulée de la classe

Borne inférieure de la 1ère classe a pour image 0

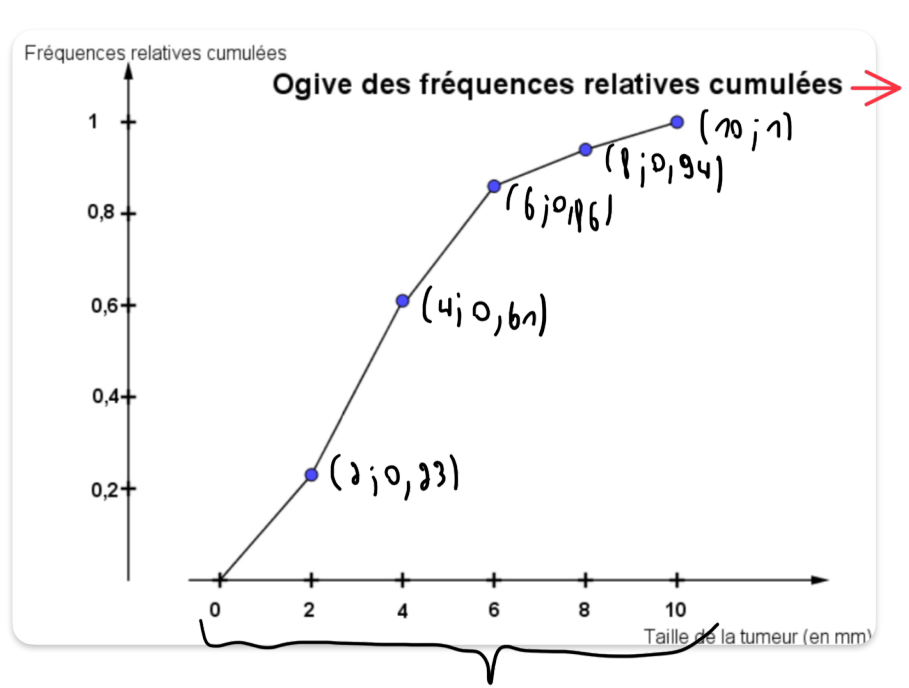

⚠ titre ⚠

Rappel : fréquences cumulées : $F_i = f_i + f_{i-1}$
Effectifs cumulés : $\sum_{i=1}^{k} m_i = N$

borne supérieure = b_i
borne inférieure = b_{i-1}