

Concepts de routage et commutation

Chapitre 8

Cours de M. Petein Thomas


Email : thomas.petein@heh.be



Chapitre 8

Introduction à la structure d'Internet


Dans cette première partie on va s'intéresser à la structure d'Internet en prenant notamment un exemple de communication entre un PC et un serveur distant.



Un ordinateur à Rennes qui se connecte sur le site www.example.com
Grâce aux outils de diagnostic des réseaux on trouve que les paquets de données échangés lors de cette connexion traversent dix routeurs.



Chapitre 8



Ces trois premiers routeurs sont gérés par RENATER : Le Réseau National de télécommunications pour la Technologie l'Enseignement et la Recherche.


Ensuite, les paquets de données traversent deux routeurs de l'opérateur Vodafone, puis le réseau de l'opérateur TeliaSonera pour atteindre un routeur situé à Washington aux Etats-Unis. Et finalement les paquets de données arrivent au serveur www.example.com hébergé par le fournisseur de contenu EdgeCast.

Chapitre 8

Cet exemple simple permet de révéler une propriété importante de la structure d'Internet : **Internet est un ensemble de réseaux gérés par différents opérateurs qui s'interconnectent afin de fournir la connectivité globale.**

Ce que l'on vient de voir est le trajet emprunté par les paquets de données pour atteindre le serveur qui héberge notre site depuis le PC situé à Rennes.

Maintenant si l'on se place d'un point de vue macroscopique (afin de masquer la complexité interne des réseaux traversés), on va voir que, réellement, l'interconnexion entre les réseaux est plus complexe.



Chapitre 8

Afin de comprendre comment se propagent les informations concernant l'accessibilité au réseau ainsi que les mécanismes et les protocoles utilisés par les réseaux d'opérateurs, on va reparler de la notion de systèmes autonomes.


Un système autonome (SA) est un ensemble de réseaux connectés généralement gérés par une même entité administrative et qui se comporte comme une seule entité pour le routage externe.

Un système autonome peut être le réseau d'un fournisseur de contenu, d'un fournisseur d'accès à Internet, ou de toute entreprise avec un accès à Internet, ...

Chapitre 8

Pour vous donner une idée, RENATER est un système autonome qui assure une couverture nationale en France.

Il dispose d'une infrastructure de transmission en fibres optiques et de points de présence dans plusieurs villes en France, avec à certains points stratégiques (comme Paris, Lyon ou Marseille) des interconnexions avec d'autres systèmes autonomes tels que les fournisseurs d'accès à Internet en France ou le réseau européen pour l'éducation et la recherche GEANT.



Chapitre 8

D'autres systèmes autonomes comme TeliaSonera assurent une couverture internationale avec des points de présence sur plusieurs continents (Amérique du Nord, Europe ou encore Asie).

Comment identifie-t-on les SA ?

Chaque système autonome est identifié par un numéro unique, codé sur 16 bits, et compris entre 1 et 65534. RENATER dispose par exemple du numéro de système autonome 2200. A noter que les 1024 derniers numéros (c-à-d de 64512 à 65534) sont destinés à un usage privé.

Au niveau de l'attribution de ces numéros uniques, exactement comme pour les adresses IP, la gestion des numéros de systèmes autonomes est faite par l'IANA (Internet Assigned Numbers Authority), qui délègue à ses organismes régionaux.



Pour l'Europe, ces numéros s'obtiennent auprès de RIPE NCC.

Chapitre 8

Aujourd'hui, il existe plus de 51 000 systèmes autonomes dans l'Internet.

→ Pour accompagner cette évolution de l'Internet, les numéros de systèmes autonomes passent de 16 à 32 bits.

A partir de janvier 2009, les numéros des SA ont notés sous le format **X.Y** (avec X et Y qui sont des entiers codés sur 16 bits).

Exemple : l'Assistance publique - Hôpitaux de Paris dispose du numéro 3.2267 attribué en 2012.

Voyons un peu à quoi cela ressemble.



Chapitre 8



Chapitre 8

Sur ce graphe, les nœuds représentent des systèmes autonomes et les liens représentent les interconnexions.

D'une part, les nœuds sont regroupés par zone géographique et d'autre part le rayon est proportionnel au nombre de voisinages.

Cette représentation permet de mettre en évidence 2 points importants :

- Plus un système autonome a des voisins, plus il est proche du centre du graphe et la densité des nœuds centraux est faible : très peu de systèmes autonomes disposent d'un très grand nombre de connexions (exemple : Level3, TeliaSonera, Cogent,...)



Chapitre 8

- Par contre la densité des nœuds se trouvant près de la frontière du graphe est très élevée. C'est là qu'on retrouve la majorité des systèmes autonomes de l'Internet et on remarque que ceux-ci sont interconnectés avec un ou deux voisins.



Chapitre 8

De l'analyse de ce graphe on peut déduire les enjeux du routage externe :

- Tout d'abord le routage externe doit offrir la connectivité globale en rendant possibles les échanges entre différents systèmes autonomes.
- Ensuite, le routage externe doit être appliqué à l'échelle de l'Internet et permettre l'échange d'informations de routage entre un très grand nombre de systèmes autonomes.
- Finalement, le routage externe doit préserver l'autonomie des SA : chaque système autonome doit pouvoir prendre les décisions d'acheminement du trafic et établir ses propres stratégies de routage.


Chapitre 8

Interconnexion entre les SA

On sait maintenant que les SA sont interconnectés entre eux mais ce que l'on va voir maintenant ce sont les types d'accords pour l'échange de trafic entre ces SA.


Il existe 2 types d'accords en systèmes autonomes :

- ✓ Le **transit** : il s'agit d'un accord commercial entre un client et un fournisseur qui assure l'acheminement du trafic du client vers ou depuis le reste de l'Internet. Dans ce cas, le fournisseur (appelé aussi opérateur de transit) facture à son client le trafic échangé.



Chapitre 8

- ✓ Le **peering** : il s'agit d'un accord d'échange direct de trafic entre deux systèmes autonomes et entre leurs clients.



Dans l'exemple ci-dessus, les systèmes autonomes A et B sont respectivement des fournisseurs de C et D.

Si A et B concluent un accord de peering, le trafic en provenance de l'un des quatre systèmes autonomes cités et à destination de l'un d'eux peut emprunter le lien d'interconnexion : c'est le cas par exemple du trafic de A vers B ou de C vers D.

Chapitre 8

Généralement le trafic échangé selon un accord de peering n'est pas facturé. Bien entendu les deux systèmes autonomes partagent le coût de la mise en place et du maintien de l'interconnexion.


C'est le cas lorsqu'un accord est conclu entre deux systèmes autonomes équivalents. La comparaison entre 2 SA se fait sur des caractéristiques tel que l'étendue géographique, la capacité des liens, le nombre de clients, ou le trafic généré.

Il va de soi que si le trafic n'est pas facturé sur un lien de peering, les deux systèmes autonomes veillent à garder un ratio équilibré des débits de trafic échangé. ($D_1 \approx D_2$)

Chapitre 8

Mais de plus en plus, depuis la forte augmentation du trafic vidéo sur Internet, cet équilibre de trafic n'est plus respecté...

Prenons l'exemple d'un fournisseur d'accès à Internet A et d'un fournisseur de contenu vidéo B. Lorsque les clients de A accèdent à un contenu vidéo hébergé par B, leurs requêtes génèrent un débit faible comparé à celui généré par le trafic de retour transportant les vidéos.



Si comme dans ce cas, le débit moyen du trafic envoyé de B vers A dépasse largement celui envoyé de A vers B, A peut demander de renégocier l'accord de peering.


Au niveau de la renégociation, A pourra :

- Soit facturer à B l'extension de la capacité du lien d'interconnexion.
- Soit facturer à B le trafic échangé.

On parle alors d'accord de **peering payant**.

Chapitre 8

Maintenant prenons un nouveau cas de figure :



Admettons maintenant que les systèmes autonomes C et D, qui auparavant échangeaient leur trafic en passant par A et B (via des accords de transit), mettent en place un accord de peering.

Quels seraient les avantages pour A et B de mettre en place un tel accord ?

Chapitre 8

Ceux-ci seraient multiples :


- Premièrement, le délai de bout en bout des communications entre C et D serait réduit, et la qualité de service proposée par les systèmes autonomes améliorée.
- Deuxièmement, C et D vont réduire ainsi la dépendance à leurs fournisseurs respectifs. En plus de cela ils profitent d'une tolérance aux pannes au niveau de leur interconnexion : si le lien direct de peering tombe en panne, le trafic échangé entre C et D peut repasser par les fournisseurs.
- Troisièmement si ils échangent directement leur trafic selon un accord de peering ils vont réduire les coûts de transit payés. A la différence du trafic échangé en transit (facturé par les fournisseurs), le peering induit uniquement des coûts de mise en place et de maintien de l'interconnexion.

Dès lors, au delà d'un débit moyen de trafic échangé, le peering devient une solution rentable pour les systèmes autonomes.

Chapitre 8

Bon, dans les exemples précédents nous avons vu que les interconnexions de peering sont réalisées au travers d'un lien direct entre les infrastructures propres des deux systèmes autonomes.

En réalité la mise en place des interconnexions de peering peut être réalisée via des points d'échange ou **Internet Exchange (IX)**. Un point d'échange est une infrastructure d'interconnexion distribuée sur plusieurs centres d'hébergement de données qui permet à des systèmes autonomes d'échanger directement leur trafic.



Chapitre 8

Le schéma logique d'un point d'échange est une plateforme de commutation sur laquelle se connecte un routeur de chaque système autonome membre.

Un SA qui souhaite se connecter au point d'échange paie des frais d'installation et des frais mensuels.

Comparé à un lien de peering direct entre systèmes autonomes, le point d'échange peut s'avérer comme une solution plus économique puisqu'un système autonome qui devient membre d'un point d'échange a la possibilité d'échanger le trafic directement avec l'ensemble des autres membres et ce moyennant un seul lien d'interconnexion avec la plateforme de commutation.


Les points d'échanges deviennent des éléments importants de la structure de l'Internet.

Par exemple un point d'échange comme FrancelX réunit plus de 250 systèmes autonomes membres et le débit moyen du trafic échangé est près de 250 Gbits/s.

Chapitre 8

Maintenant, pour en revenir aux systèmes autonomes dans l'Internet, et en considérant les accords de peering et de transit, on peut classer les SA en 3 niveaux :

Ces niveaux sont appelés « Tier » en anglais et on retrouve donc des SA de niveau 1 ou « Tier 1 », de niveau 2 ou « Tier 2 » et finalement de niveau 3 « Tier 3 ».



Chapitre 8

Les systèmes autonomes de niveau 1


Un système autonome de niveau 1 (ou Tier 1) fournit un transit pour ses clients et dispose d'un ensemble d'accord de peering.

Ces deux types d'accord lui permettent de joindre tous les systèmes autonomes de l'Internet.

Les systèmes autonomes de niveau 1 ont des accords de peering mutuels, et constituent une sorte de coeur de l'Internet (exemple : AT&T, TeliaSonera, Level3, Cogent)

La stratégie de peering appliquée par les systèmes autonomes de niveau 1 est dite **restrictive**.


Cela impose à tout système autonome candidat pour un accord de peering des contraintes très strictes de couverture géographique, de capacité, et d'équilibre de trafic échangé.



Chapitre 8

Les systèmes autonomes de niveau 2

Les systèmes autonomes de niveau 2 (ou Tier 2) sont mixtes : ils dépendent d'un fournisseur de transit, généralement de niveau 1, et proposent à leur tour une offre de transit à leurs clients.




Un système autonome de niveau 2 applique une stratégie de peering **sélective**. Il négocie pour conclure des accords de peering avec des systèmes autonomes équivalents, ce qui permet de réduire les factures de transit.

Chapitre 8

Les systèmes autonomes de niveau 3

Les systèmes autonomes de niveau 3 (ou Tier 3) sont clients de fournisseurs de transit de niveau supérieur.



Ils ne proposent pas d'offre de transit. Un système autonome de niveau 3 applique généralement une stratégie de peering **ouverte** et cherche à s'interconnecter aux points d'échange pour réduire les factures de transit.

Chapitre 8

Principes de routage externe et stratégies de routage


On va maintenant s'intéresser aux principes du routage externe et donc voir comment se passe l'échange d'informations. Ensuite on analysera la mise en place de stratégie de routage.

Sur Internet, chaque système autonome gère un ou plusieurs blocs contigus d'adresses IP appelés préfixes. Ces préfixes servent à numérotter les équipements du système autonome ou ceux de ses clients.

La mise en place du routage externe permet de rendre joignables ces préfixes sur Internet. Ici dans l'exemple on considère que le système autonome A qui gère les préfixes 10.1.0.0/16 et 192.168.1.0/24.


→ Grâce au routage externe, le routeur du système autonome A va annoncer ses préfixes à son voisin B.

→ le routeur du système autonome B met en place deux entrées dans la table de routage qui permettent de router le trafic vers les préfixes de A.



Chapitre 8

Bien évidemment B doit annoncer le préfixe 192.168.2.0/24 qu'il gère.




A la réception des annonces du protocole de routage, le routeur de A met en place une entrée correspondante dans la table de routage pour joindre le préfixe de B.

Chapitre 8

Alors je rappelle qu'il n'existe pas de SA central dans l'Internet !


→ le relayage des annonces de préfixes est une fonction importante du routage externe.



Supposons que le système autonome A a deux voisins (qui sont B et C). Grâce au protocole de routage externe, les routeurs du système autonome A annoncent ses préfixes aux voisins B et C.

Chapitre 8

De même, les routeurs de B et C peuvent relayer l'information vers les systèmes autonomes D et E. Ainsi, de proche en proche l'information se propage pour atteindre tous les systèmes autonomes de l'Internet.




Chapitre 8

La possibilité de mettre en place des *stratégies de routage* est une caractéristique principale du routage externe. D'une manière simple, une stratégie de routage externe consiste à contrôler l'envoi des annonces de préfixes et le traitement des annonces reçues.

Chaque SA peut décider de sa stratégie de routage !


Exemple de mise en place de stratégie de routage :



Chapitre 8

Commençons par l'*annonce sélective de préfixes* qui permet à un système autonome de contrôler le trafic entrant.

Dans notre exemple, système autonome A choisit d'annoncer le préfixe 10.1.0.0/16 vers son voisin B, et le préfixe 192.168.1.0/24 vers son voisin D.



L'annonce du préfixe 192.168.1.0/24 peut être relayée de D, vers E, C, puis vers B.


Les routeurs de B peuvent maintenant mettre en place des entrées dans leur table de routage.

- Le trafic de B à destination de 10.1.0.0 /16 sera directement transmis à A
- le trafic à destination de 192.168.1.0/24 sera transmis vers C puis E, D, et enfin A.

Chapitre 8

Maintenant prenons l'exemple d'une stratégie de routage basée sur la *sélection des annonces reçues*.

Cette fois-ci le système autonome A annonce ses 2 préfixes 10.1.0.0/16 à ces voisins B et D.



D relaye l'annonce qui arrive de proche en proche jusqu'à B.

Ainsi, B reçoit les annonces des préfixes de A via ses deux voisins.

B peut alors choisir de mettre en place une stratégie de routage basée sur la préférence des annonces reçues.


Il peut par exemple choisir de préférer l'annonce en provenance de A pour le préfixe 10.1.0.0/16 et celle en provenance de C pour le préfixe 192.168.1.0/24.

Chapitre 8

Routage interne et routage externe

Dans l'exemple ci-dessous, et grâce aux informations de routage externe, le système autonome A achemine son trafic via B pour atteindre C.

Mais comment est routé le trafic qui va de A vers C lorsqu'il passe par le système autonome B ?



Tout d'abord il y a de fortes chances que le système autonome B soit composé de différents routeurs... Pour notre exemple on dira que le système autonome B dispose d'une infrastructure avec cinq points de présence qui sont les routeurs B1 à B5, avec B1 et B5 qui assurent l'échange d'informations de routage externe.

En plus du routage externe, le système autonome B déploie un routage interne qui permet de calculer les meilleurs chemins entre ses différents routeurs.

Si le meilleur chemin entre B1 et B5 passe par B2, alors ce segment de chemin permet de traverser B et vient donc compléter le chemin de bout en bout entre A et C.

Chapitre 8

On remarque donc que le routage externe et interne sont donc deux fonctions complémentaires mais indépendantes !

Premièrement, le routage externe est déployé entre deux systèmes autonomes différents. Ceci impose des règles de contrôle des annonces de routage reçues depuis les voisins. Dans le routage interne, les routeurs voisins sont forcément de confiance puisqu'ils font partie d'un même système autonome.

Deuxièmement, le routage externe offre la possibilité de mettre en place des stratégies de routage en filtrant les annonces envoyées ou reçues. Au contraire, le routage interne est basé sur le principe de la diffusion des informations de routage entre tous les routeurs.

Finalement, le routage externe se base sur les stratégies de routage et les types d'accords entre les systèmes autonomes pour calculer le meilleur chemin. Alors que ce même calcul repose sur des métriques techniques telles que le nombre de routeurs traversés ou la capacité des liens dans le cas du routage interne.

Chapitre 8

Ce qui peut se résumer à ce tableau :

Routage externe	Routage interne
Deux systèmes autonomes différents	Intérieur d'un même système autonome
Mise en place de stratégies de routage	Diffusion des informations de routage
Calcul des routes en fonction des stratégies de routage	Calcul des routes en fonction de métriques techniques

Chapitre 8

Sessions et messages utilisés par BGP


BGP (*Border Gateway Protocol*) est le seul protocole de routage externe déployé sur Internet. La version 4 actuellement utilisée est définie dans le RFC 4271 de l'IETF.

Comme vous l'aurez maintenant compris, les systèmes autonomes utilisent BGP pour annoncer leurs préfixes d'adresses IP et pour mettre en place leurs stratégies de routage.

Dans quel cas de figure doit-on mettre en place BGP ?


Lorsqu'un réseau dispose d'un seul fournisseur, et qu'il n'a pas besoin d'établir une stratégie de routage externe, la mise en place de BGP n'est pas nécessaire.

Par contre BGP devient nécessaire quand un système autonome dispose de plusieurs fournisseurs (on parle alors de multi-domiciliation). BGP permet dans ce cas d'appliquer des stratégies de routage.



Chapitre 8


Le deuxième cas de figure qui nécessite typiquement la mise en place de BGP est celui d'un fournisseur qui offre le transit à d'autres systèmes autonomes.



Chapitre 8

BGP est un protocole de type vecteur de chemins (ou « path-vector »), c-à-d qu'un message BGP qui annonce un préfixe contient aussi la liste des systèmes autonomes à traverser pour atteindre ce préfixe.

Prenons l'exemple d'un système autonome A qui gère le préfixe 10.1.0.0/16 et qui est connecté à un système autonome B, lui-même connecté à un troisième système autonome C.



Le message BGP envoyé par le routeur A1 vers le routeur B1 permet d'annoncer le préfixe de A. La liste de systèmes autonomes à traverser contient le numéro de A.

Ensuite, si la stratégie de routage de B le permet, un message BGP est envoyé par B2 vers C1 pour annoncer le préfixe de A ainsi que la liste de systèmes autonomes à traverser (qui contient le numéro de B suivi par celui de A).

Chapitre 8


Les propriétés d'un protocole de type vecteur de chemins permettent à BGP de répondre à deux enjeux importants du routage externe :

- Premièrement, l'information du chemin de systèmes autonomes à traverser est une information macroscopique. Elle permet de masquer toute la complexité interne et les états de liens dans chaque système autonome.
- Deuxièmement, chaque système autonome décide des annonces de préfixes et du traitement des annonces reçues par BGP. Ceci permet la mise en place de stratégies de routage et préserve l'autonomie des décisions.

Chapitre 8

Le protocole BGP appartient à la couche applicative selon le modèle TCP/IP.


Il s'appuie sur le protocole de transport TCP. Ceci permet de s'affranchir de la nécessité de supporter explicitement les fonctions de fragmentation, de retransmission, d'acquittement et de séquençement qui sont des fonctions naturellement supportées par le protocole TCP.



Les messages BGP sont donc transportés dans des segments TCP, auxquels s'ajoutent les entêtes des couches inférieures (IP et Ethernet par exemple) avant d'être transmis sur la couche physique.

Chapitre 8

Pour annoncer leurs préfixes, les systèmes autonomes établissent une session BGP entre leurs routeurs. Dans l'exemple des systèmes autonomes A et B, une session BGP est établie entre les routeurs A1 et B1.




Cette session permet d'échanger des messages BGP : un message est envoyé de A1 vers B1 pour annoncer le préfixe 10.1.0.0/16 de A.

Un autre message est envoyé de B1 vers A1 pour annoncer le préfixe 10.2.0.0/16 de B.

Chapitre 8

Prenons l'exemple de quatre systèmes autonomes A, B, C, et D. En particulier, le système autonome A gère le préfixe 10.1.0.0/16.



Les routeurs A1 et B1 établissent une session BGP qui permet à A1 d'annoncer le préfixe de A.


Supposons que la stratégie de routage de B consiste à annoncer le préfixe de A vers C et D, comment les routeurs B2 et B3 sont-ils informés de ce préfixe ?

→ Grâce à des sessions BGP qu'établissent les routeurs B1, B2 et B3 du système autonome B.

Chapitre 8

En fait il existe 2 types de sessions BGP qui servent à échanger les préfixes :

- Les sessions entre routeurs de deux systèmes autonomes différents par exemple A1 et B1. Ces sessions sont appelées **eBGP** ou **external BGP**.
- Les sessions entre routeurs du même système autonome par exemple B1 et B2. Ces sessions sont appelées **iBGP** ou **internal BGP**.




Afin de garder une vue cohérente des préfixes appris par BGP, les systèmes autonomes mettent en place des sessions iBGP entre tous leurs routeurs BGP.

Chapitre 8

Quelle relation existe entre iBGP et le routage interne ?

Même si les sessions iBGP sont établies entre les routeurs d'un même système autonome, il s'agit toujours de sessions de routage externe.

Supposons qu'après l'établissement des sessions eBGP et iBGP, le système autonome C reçoit l'annonce du préfixe 10.1.0.0/16 de A. Il sait maintenant qu'il peut le joindre A à travers B.



L'échange iBGP permet de déterminer que le trafic doit être routé de B2 vers B1.

Au niveau du calcul du chemin interne entre B2 et B1, ce calcul dépend du protocole de routage interne de B. Si le meilleur chemin calculé par le routage interne entre B1 et B2 passe par B4, alors ce segment vient compléter le chemin de bout en bout de C vers A.

Chapitre 8


Les types de messages BGP

Au niveau des types de messages, le protocole BGP utilise quatre types de messages servant à l'établissement de session, son maintien, à l'échange de préfixes et à la fermeture de session.

- Le message **OPEN** sert à ouvrir la session BGP, il permet d'annoncer les numéros de systèmes autonomes et les identifiants des routeurs. L'ouverture de la session fait suite à un accord entre les deux systèmes autonomes et une désignation des équipements pour la mettre en œuvre.
- Le message **KEEPALIVE** est envoyé périodiquement afin de maintenir la session BGP. Celle-ci sera fermée si aucun message KeepAlive n'est reçu pendant une période prédéfinie.
- Le message **NOTIFICATION** sert à signaler des erreurs. La session est immédiatement fermée suite à l'émission de ce message.
- Le message **UPDATE** contient la liste des préfixes qu'un routeur souhaite annoncer (ou dont il souhaite supprimer l'annonce) ainsi que les différents attributs associés.

Chapitre 8

Voyons un peu les différentes phases d'un échange BGP entre deux routeurs.



Au préalable, une connexion TCP sur le port serveur 179 est établie entre les deux routeurs.

Sur cette connexion le routeur A et le routeur B envoient des messages d'ouverture de session.

Si l'ouverture de session est acceptée, les routeurs acquittent par des messages KEEPALIVE. Ces messages KEEPALIVE sont envoyés périodiquement pour maintenir la session BGP entre les routeurs.

Ensuite, chaque routeur annonce la liste de préfixes joignables dans des messages update.

Chapitre 8

Une fois que deux routeurs ont échangés la liste des préfixes joignables à l'aide de messages UPDATE, si un changement a lieu pour un préfixe (dû à une suppression ou une modification des attributs), seul le préfixe modifié sera annoncé par un message UPDATE.

Chapitre 8

Attributs du protocole BGP

Nous avons vu juste avant que les messages UPDATE contiennent la liste des préfixes qu'un routeur souhaite annoncer ainsi que différents attributs associés. Nous allons donc nous pencher sur les différentes propriétés transportées dans les messages d'annonce de préfixes et de leur utilisation dans le routage BGP.

Il existe 6 attributs utilisés dans les annonces BGP :


- AS_PATH
- NEXT_HOP
- LOCAL_PREF
- MED
- ORIGIN
- COMMUNITIES

Chapitre 8

L'attribut AS_PATH

Dans les messages BGP, les routeurs annoncent obligatoirement pour chaque préfixe un attribut qui renseigne le chemin de systèmes autonomes. Cet attribut est noté AS_PATH.

Comment ça marche ?



Admettons un système autonome A qui gère et annonce son préfixe au système autonome B. Dans ce cas, l'attribut AS_PATH contient le numéro A.


Ensuite cette annonce est relayée par iBGP jusqu'à B2, sans modification de l'AS_PATH.

Finalement, si la stratégie de routage du système autonome B l'autorise, un message BGP sera envoyé par B2 vers C1 afin d'annoncer le préfixe de A. Dans ce message, l'AS_PATH contient le numéro de B suivi par celui de A.

Chapitre 8

Au niveau du routage externe, l'attribut AS_PATH joue deux rôles :

- Il permet de détecter des boucles dans le chemin de systèmes autonomes.




Supposons que le système autonome A annonce le préfixe 10.1.0.0/16 à son voisin B.

Imaginons que cette annonce soit relayée par les systèmes autonomes B, C et D. Elle sera finalement retransmise vers A...

Lorsque le routeur A2 reçoit l'annonce BGP, l'AS_PATH contient (D C B A). A2 note la présence de son propre numéro de système autonome dans l'AS_PATH. Une boucle est alors détectée et l'information de routage reçue par A2 est ignorée !

Chapitre 8

- Il permet de gérer des stratégies de routage.



Supposons que le système autonome C a reçu deux annonces de routage concernant le préfixe 10.1.0.0/16 géré par A :

- une première annonce via le chemin (A B);
- une deuxième via (A E D).

Dans ce cas, le système autonome C peut appliquer une stratégie de routage en fonction de ce paramètre.


Il pourra par exemple préférer le chemin de systèmes autonomes le plus court (c-à-d le chemin passant par B puis A) et envoyer son trafic par là.

Il pourrait aussi appliquer une stratégie de routage pour exclure le chemin qui contient B. De cette façon le trafic de C empruntera le chemin (C D E A).

Chapitre 8

L'attribut NEXT_HOP

Cet attribut obligatoire permet de désigner le prochain saut pour joindre une destination.



Lorsque le routeur A1 annonce le préfixe 10.1.0.0/16 l'attribut NEXT_HOP contient l'adresse IP de A1.

Par défaut, cet attribut n'est pas modifié par iBGP dans le système autonome B.

Par contre lorsque B2 annonce le préfixe de A vers C1, il modifie la valeur du NEXT_HOP pour mettre sa propre adresse.

Chapitre 8

Remarque :

Notons que pour les routeurs de B, en particulier B2, A1 est le prochain saut vers 10.1.0.0/16.

→ Le routeur B2 doit donc pouvoir joindre A1 qui est dans un autre système autonome.

Comment cela est-il possible en pratique ?


Il existe deux solutions à ce problème :

- La première consiste à annoncer l'adresse IP de A1 dans le protocole de routage interne du système autonome B. Ainsi, B2 peut joindre A1 via le meilleur chemin calculé selon les métriques du routage interne.
- La deuxième consiste à configurer B1 pour mettre son adresse IP dans l'attribut NEXT_HOP de l'annonce iBGP.

Chapitre 8

L'attribut LOCAL_PREF

L'attribut LOCAL_PREF est attribut iBGP facultatif qui permet de contrôler la route empruntée par le trafic en sortie d'un système autonome.




Supposons que le système autonome C a reçu deux annonces de routage pour le préfixe 10.1.0.0/16.

L'opérateur du système autonome C peut configurer l'attribut LOCAL_PREF de ces routeurs C1 et C2. Si par exemple C1 ajoute une préférence locale égale à 300 dans ses annonces iBGP, alors que C2 ajoute une préférence local égale à 200, tout le trafic du système autonome C à destination de 10.1.0.0/16 sortira par le routeur C1 puisqu'il a la valeur LOCAL_PREF la plus élevée !

Chapitre 8

L'attribut MED

L'attribut MED (pour Multi-Exit Discriminator) est attribut optionnel eBGP qui permet de contrôler la route empruntée par le trafic en entrée d'un système autonome.



Généralement, l'attribut MED est utilisé dans le cas de deux systèmes autonomes qui ont mis en place plusieurs liens d'interconnexion. Supposons que les systèmes autonomes A et B disposent de deux liens d'interconnexion.

Le système autonome A peut choisir de configurer ses routeurs pour envoyer dans les annonces de préfixe un attribut MED (par exemple MED = 2000 pour A1 et MED = 1000 pour A2).

Les routeurs B1 et B2 reçoivent ces messages et échangent ensuite l'information de routage par iBGP avec l'attribut MED non modifié. Le trafic du système autonome B à destination de 10.1.0.0/16 sera envoyé via le lien B2-A2 car celui-ci a la valeur MED la plus petite !

Chapitre 8

L'attribut ORIGIN

L'attribut ORIGIN est un attribut obligatoire qui permet de décrire l'origine de l'information de routage pour le préfixe annoncé.

Trois valeurs possibles ont été définies pour cet attribut :

- Lorsque l'attribut a pour valeur « 0 », le préfixe annoncé par BGP est interne au système autonome qui a généré l'information.
- Lorsque l'attribut a pour valeur « 1 », le préfixe annoncé par BGP est externe au système autonome qui a généré l'information.
- Lorsque l'attribut a pour valeur « 2 », l'origine de l'information est incomplète. Le préfixe correspondant a par exemple été injecté dans BGP par un processus de redistribution statique ou dynamique.


A savoir que pour un même préfixe, une annonce avec l'attribut ORIGIN égal à 0 est préférée à une annonce avec l'attribut égal à 1, qui à son tour est préférée à une annonce avec la valeur 2.

Chapitre 8

L'attribut COMMUNITIES

L'attribut COMMUNITIES est un attribut optionnel qui permet d'appliquer une même stratégie à un groupe de préfixes annoncés par BGP. Cette stratégie peut consister à contrôler l'acceptation, le relayage, ou la modification des attributs du groupe de préfixes.

L'objectif principal de la mise en place des communautés est la simplification de configuration des routeurs BGP. En particulier, il est d'usage de mettre en place des communautés par types de clients, par région géographique, ou selon l'accord d'échange de trafic entre les voisins.



Exemple :

Si le système autonome A qui annonce à B son préfixe 10.1.0.0/16 avec la communauté no-export, les routeurs de B relayent cette information par iBGP mais ne l'annoncent pas à C.

→ C dispose uniquement du chemin via D et E pour atteindre le préfixe de A.

→ B peut utiliser le lien direct avec A.

Chapitre 8

D'autres communautés peuvent être définies par les systèmes autonomes. Généralement, les communautés sont notées sous le format :
 « *numéro_AS (2 octets):numéro_communauté (2 octets)* »

Autre exemple : l'AS 100 peut avoir pour politique d'attribuer une Local Preference 200 en présence de la community 100:200, ceci permet à un AS d'influencer le routage à l'intérieur d'autres AS.

Bref la communauté BGP est un attribut flexible qui permet d'appliquer une même stratégie à un groupe de préfixes annoncés par BGP.

Remarque :

Comme nous l'avons vu, l'introduction de numéros d'AS sur 32 bits pose problème avec l'attribut community (qui ne peut recevoir qu'un AS sur 16 bits, ce qui rend inopérante la correspondance entre ce champ et la véritable valeur de l'AS).


→ Un attribut « Large Community » est apparu et il est composé de 12 octets divisés en 3 parties de 4 octets chacun (AS:fonction:paramètre)

Chapitre 8

Processus de sélection dans BGP

Maintenant on va essayer de voir quelles sont les différentes étapes qui permettent de comparer les annonces de préfixes et du traitement des informations de routage obtenues par BGP.

Sur Internet il existe souvent plusieurs chemins qui permettent de joindre un même préfixe. C'est cette diversité rend le routage externe robuste en cas de pannes dans l'un des systèmes autonomes.



Prenons l'exemple du système autonome C qui reçoit l'annonce du préfixe de A via le chemin (B A), et via le chemin (D E A).

C doit sélectionner une des annonces pour mettre en place une entrée correspondante dans sa table de routage (qui servira à router le trafic de C vers A).

Chapitre 8

Dans ce contexte, les questions à se poser sont les suivantes :

Comment un système autonome sélectionne-t-il une annonce parmi celles reçues ?

Quels sont les critères qui sont pris en compte ?

Quels sont les attributs transportés dans les messages BGP qui interviennent dans cette sélection ?

Le processus de sélection prend en compte une suite de critères.


Les annonces candidates sont comparées en utilisant chacun des critères dans l'ordre indiqué.

Au début du processus, les annonces candidates correspondent à toutes les annonces reçues pour un même préfixe.

A chaque critère, certaines annonces peuvent être écartées. Le processus s'arrête alors lorsque le résultat de la comparaison permet de sélectionner une et une seule annonce.

Chapitre 8

Le premier critère de comparaison est la valeur de l'attribut de préférence locale (LOCAL_PREF) transportée dans les messages iBGP. L'annonce avec la valeur de préférence locale la plus élevée est sélectionnée.




Dans cet exemple, le routeur C3 reçoit deux annonces en provenance de C1 et C2 avec une valeur de l'attribut de préférence locale égal à 200 et 100 respectivement.

Dans ce cas, l'annonce en provenance de C1 est sélectionnée et le processus s'arrête.

Chapitre 8

Le premier critère étudié peut ne pas aboutir à la sélection d'une seule annonce : ceci se présente lorsque l'attribut de préférence locale n'est pas utilisé ou lorsque plusieurs annonces vers le même préfixe ont la même valeur de LOCAL_PREF.



Dans ce cas, le processus de sélection passe au deuxième critère, qui correspond à la longueur du chemin de systèmes autonomes pour joindre le préfixe annoncé.

Ici C1 reçoit une annonce qui indique qu'il faut traverser deux systèmes autonomes pour joindre le préfixe de A.

Alors que celle en provenance de C2 indique un chemin de trois systèmes autonomes.

→ Dans ce cas, la première annonce est sélectionnée.

Chapitre 8

Rappelons-nous que rien ne garantit que le chemin le plus court en termes de systèmes autonomes soit le meilleur, que ce soit en débit ou en latence ou en termes de routeurs traversés.

Après l'AS_PATH, on compare l'attribut ORIGIN des annonces candidates restantes.

Selon cet attribut, les annonces sont sélectionnées dans l'ordre suivant :


Un préfixe interne au système autonome qu'il a généré l'emporte sur un préfixe externe à ce système autonome, qui à son tour l'emporte sur un préfixé appris par un processus de redistribution statique ou dynamique.

Après cela vient le moment de passer à la comparaison de l'attribut MED (contenu dans les annonces candidates) qui permet de proposer à un système autonome voisin un lien préféré pour le trafic entrant. L'annonce avec la valeur MED la plus petite est sélectionnée.

Ensuite le processus de sélection va comparer le type de session BGP. L'annonce du préfixe en provenance d'un routeur d'un système autonome différent est préférée à une annonce en provenance du même système autonome.

Chapitre 8

Si l'on reprend toujours notre même exemple, le routeur C1 reçoit une annonce eBGP du préfixe de A en provenance de B2, et deux annonces iBGP en provenance de C2 et C3.



Selon ce critère, l'annonce en provenance de B2 est sélectionnée.

Ainsi, C1 route le trafic vers A en passant par B2 au lieu de passer par C2 ou C3.


Globalement, ce critère permet de préserver les ressources du système autonome qui va préférer router le trafic directement vers le voisin.

Chapitre 8

En poursuivant sur le même objectif de préservation des ressources, le prochain critère de comparaison est le coût du chemin interne.

L'annonce qui utilise le chemin le plus court vers le prochain saut est sélectionnée.

En général, le coût du chemin est évalué selon la métrique du routage interne.



C3 qui reçoit deux annonces du préfixe de A. La première indique un prochain saut qui est C1 avec une métrique égale à 10, la deuxième annonce propose de passer par C2 avec une métrique égale à 100.

→ l'annonce en provenance du routeur C1 est sélectionnée.

Ce critère permet de joindre le plus rapidement la sortie du système autonome, afin de minimiser l'utilisation des ressources internes telles que la capacité sur les liens.

Chapitre 8

Si le processus ne réussit pas à départager les annonces candidates après la suite des critères analysés précédemment, un dernier critère est introduit.

Ce critère est typiquement basé sur les identifiants ou les adresses IP inclut dans l'attribut NEXT_HOP.

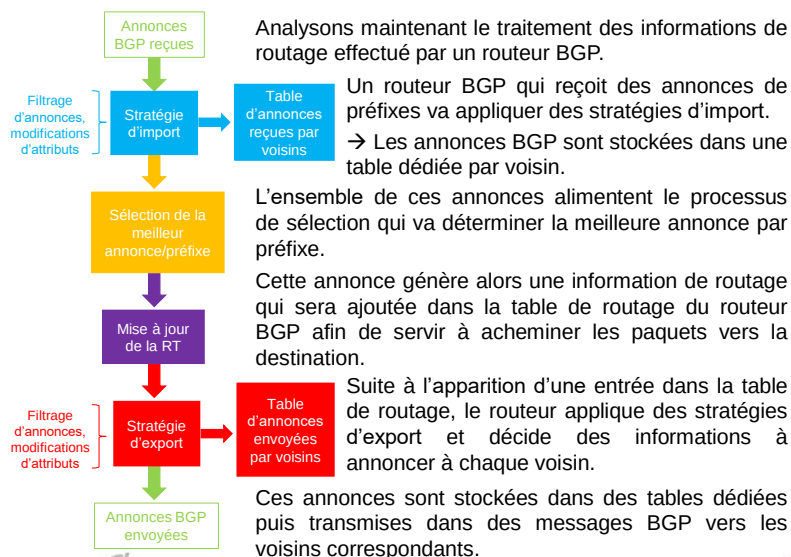
→ l'annonce en provenance du routeur avec l'identifiant le plus petit est sélectionnée et le processus s'arrête.

Chapitre 8

Synthèse concernant les critères du processus de sélection des annonces BGP :


- LOCAL_PREF : la plus grande valeur
- AS_PATH : le plus court chemin
- ORIGIN : préfixe interne > préfixe externe > préfixe redistribué
- MED : la plus petite valeur
- Type de session BGP : eBGP > iBGP
- Routage interne : chemin le plus court par rapport au routage interne
- NEXT_HOP : le plus petit indentifiant

Chapitre 8



Chapitre 8

Prenons un exemple pour illustrer le traitement des informations de routage dans BGP :



Considérons cinq routeurs qui ont établi des sessions de routage BGP.

Le routeur R2 annonce à R1 le préfixe 10.1.0.0/16 avec un AS_PATH contenant deux systèmes autonomes.

Le routeur R3 annonce à R1 le même préfixe avec un AS_PATH contenant trois systèmes autonomes.

A la réception de ces annonces, R1 applique les stratégies d'import. Supposons que ces stratégies sont transparentes dans cet exemple.


→ R1 stocke les annonces reçues dans les tables dédiées à chaque voisin R2 et R3.

Chapitre 8

Le processus de sélection traite ensuite l'ensemble des annonces reçues pour le préfixe 10.1.0.0/16.

En comparant la longueur des chemins de systèmes autonomes, R1 sélectionne l'annonce en provenance de R2. Cette annonce est injectée dans la table de routage de R1 qui peut désormais router les paquets vers 10.1.0.0/16 en passant par R2.

L'étape suivante consiste à annoncer ce préfixe aux voisins de R1. Supposons que la stratégie d'export lui autorise uniquement d'annoncer ce préfixe vers R4.



Dans ce cas, cette annonce est stockée dans la table d'annonces envoyées dédiée à R4 en mettant un attribut NEXT_HOP qui correspond à l'adresse de R1.

Finalement un message BGP est envoyé à R4.